Relatório de Síntese Consolidado — RSL "Agentic AI Copilot para Resposta a Incidentes" (Ciclos 1 e 2)

> 🧭 **Navegação:** 🏠 README raiz · 📊 Dashboard · 📄 Síntese do ciclo 1 · 🔀 PRISMA · 🧱 CSV ciclo 1 · 🧱 CSV ciclo 2

Data: 2026-09-10 · **Escopo:** síntese narrativa consolidada dos dois ciclos de atualização da RSL, sobre o corpus fundacional do Trabalho I (P01–P19). O relatório do ciclo 1 permanece como registro histórico; este documento **não o substitui** — consolida.

---

1. Resumo executivo

A RSL acumula **dois ciclos de atualização** sobre a revisão fundacional (19 estudos, P01–P19). O **ciclo 1** (jul/2026) triou 20 candidatos e incluiu **14** (7 plenos · 5 com ressalvas · 2 fundacionais condicionais), elevando o corpus a **33**. O **ciclo 2** (set/2026) processou **49 candidatos** identificados pelo autor (P41–P89), excluiu 27 na triagem com evidência PICOC de leitura integral, avaliou 22 na íntegra e incluiu **20, todos com ressalvas** (5 fundacionais condicionais · 3 com ressalva de estrato por emenda de protocolo), levando o **corpus consolidado a 53 estudos**.

Os dois ciclos convergem no achado central da tese: **a literatura quase não mede MTTD/MTTR nominalmente**. No ciclo 1, nenhum dos 39 estudos P01–P40 o fazia. No ciclo 2, um único estudo (P76) mede MTTR de um sistema agêntico — em PoC, contra referência da literatura (não baseline próprio) e com resultado **desfavorável** ao sistema proposto. Em compensação, o ciclo 2 acrescenta duas frentes novas: **evidência secundária quantificada** de MTTD/MTTR em SOC (P79: CyberAlly com MTTR de 8 h → 90 min; GreyMatter com 98% dos alertas automatizados e contenção < 5 min) e um **cluster de medição direta de carga cognitiva/fadiga de operadores** (P62, P69, P81), inexistente no ciclo 1 — fechando parcialmente a segunda lacuna da tese (COGNITIVE_LOAD), ainda que fora do domínio de TI.

2. Funil PRISMA consolidado

Etapa	Ciclo 1	Ciclo 2
Identificados	≈51 registros (3 assistentes) → 21 candidatos	49 candidatos (P41–P89, `Papers_Index.csv`)
Triagem bibliométrica	20 triados · 2 inelegíveis (Qualis A3: P39, P40)	49 triados · 4 fora de estrato **mantidos com ressalva** (emenda 2026-09-09)
Triagem temática	— (E2/E3 aplicados só após avaliação)	**27 excluídos** com evidência PICOC (E2 = 19 · E3 = 8)
Avaliados na íntegra	18	22
Excluídos pós-avaliação	4 (P26, P29, P30, P38)	2 (P85, P86)
Incluídos	**14**	**20**
Corpus acumulado	33 (19 + 14)	**53 (33 + 20)**

Diagramas completos em `PRISMA.md`. Diferença metodológica relevante: no ciclo 2 a exclusão temática pôde ocorrer **na triagem** porque a extração PICOC de leitura integral (`picoc-results-consolidated-P41-P89-Claude.md`) forneceu evidência auditável antes da avaliação — no ciclo 1, os equivalentes (P26/P29/P30/P38) só caíram após avaliação completa, e são os precedentes citados em cada exclusão do ciclo 2 (`triagem-ciclo2.md`).

3. Composição do corpus consolidado (n = 53)

- **19 fundacionais** do Trabalho I (P01–P19).
- **14 do ciclo 1** (P20–P37): núcleo agêntico×IR — LLM multi-agente (P27, P28, P31, P35), closed-loop (P22), SLM-agente (P21), MAS/RL não-LLM (P25), copilot IR (P34), GNN+LLM (P23, P32), IaC (P20), governança/adoção (P37) + 2 fundacionais (P24, P33).
- **20 do ciclo 2** (P43–P88): Agentic AIOps e SOC (P43, P76, P83, P87), LLM×IR/forense (P53, P78), telemetria agêntica (P55), MAS self-healing (P88, análogo a P25), alert fatigue (P73), LLMOps (P74), predictive maintenance agêntico (P82) + **5 fundacionais** (P52, P54, P72, P77, P79) + **cluster humano/carga cognitiva** (P62, P69, P81) + instrumento HCI (P63).
- **Fundacionais condicionais: 7 no total** (P24, P33, P52, P54, P72, P77, P79) — se o protocolo restringir o corpus a estudos primários, migram para a fundamentação (corpus primário: 46).
- **Ressalvas de estrato (emenda 2026-09-09): 3 incluídos** — P62, P69 (Qualis A3) e P81 (A4); a ressalva é obrigatória em qualquer uso na síntese.

4. Cobertura das questões de pesquisa nos dois ciclos

A lacuna sistemática **migrou de RQ4 para RQ3** entre os ciclos:

- **Ciclo 1** (18 avaliados): forte em RQ1–RQ3 (estudos empíricos de sistemas agênticos), fraco em **RQ4 (Ética & Desafios)** — só 4/18 plenas.
- **Ciclo 2** (22 avaliados): perfil invertido — os surveys fundacionais cobrem bem RQ1/RQ4/RQ5 (P79 é o único RQ pleno 5,0/5,0 de toda a RSL; P54 e P55 com 4,5), mas **RQ3 (Evidence Benefits) é a maior lacuna**: nenhum estudo do ciclo 2 recebeu "Incluir" pleno, e QA3 (base de evidências) concentra os N — 8 estudos secundários/conceituais sem validação empírica própria.

Leitura combinada: o corpus consolidado tem **fundamentação conceitual abundante e evidência empírica de benefício escassa** — exatamente a justificativa da pergunta de pesquisa da dissertação. Gráficos: ciclo 1 · ciclo 2.

5. Qualidade (QA/DARE) comparada

Métrica	Ciclo 1 (18)	Ciclo 2 (22)
SCORE_RQ médio (mediana)	3,83 (4,0)	3,16 (3,5)
SCORE_QA médio (mediana)	3,50 (3,75)	2,75 (2,75)
Banda Alta / Média / Baixa	14 / 4 / 0	11 / 10 / 1
Recomendação "Incluir" plena	7	**0**

A queda de qualidade média do ciclo 2 não é ruído: o lote é dominado por revisões e propostas conceituais (QA3 = N recorrente), enquanto o ciclo 1 concentrava protótipos e experimentos. Destaques de qualidade do ciclo 2: **P73** e **P88** (QA 4,0/4,0), **P78** e **P87** (QA 3,5, Banda Alta). Piores: P74 (QA 1,0, Banda Baixa — mantido só como fonte conceitual LLMOps).

6. Evidência sobre MTTD/MTTR e carga cognitiva (núcleo da tese)

MTTD/MTTR nominal. Situação consolidada após 89 candidatos avaliados em dois ciclos:

- **P76** (ciclo 2) — único estudo que **mede MTTR** de um sistema agêntico: fases de ~1 min a 1,5 min em PoC de SOC (brute-force SSH), comparadas ao Microsoft Copilot for Security **via literatura** (~30–45 s) — sem baseline próprio e com o sistema proposto mais lento que a referência.
- **P79** (ciclo 2, secundário) — evidência citada de estudos primários: CyberAlly (MTTR 8 h → 90 min; falsos positivos 70% → 35%), GreyMatter (98% dos alertas automatizados, contenção < 5 min), baseline setorial de 277 dias (204 detectar + 73 conter).
- **Proxies quantitativos** — P73: redução global de alertas de 74–84% (alert fatigue, Outcome nomeado); P81: reaction time do operador de ~276 s → ~107 s com DSS (Wilcoxon p = 0,00); P87: latência ponta a ponta de 2,9–11,6 s por incidente com pré-detecção em 0,3 s; P83: qualidade de resposta do copilot (BERTScore ≈ 85–87%), sem tempos.
- **Todo o restante do corpus** reporta proxies de detecção (accuracy/F1/AUC) ou alegações qualitativas ("reduces response time") sem medição.

Conclusão que os dois ciclos sustentam: não existe, no corpus, um estudo que meça MTTD **e** MTTR nominalmente, com baseline próprio, em ambiente de produção — a lacuna que a dissertação ataca permanece aberta e agora está **triangulada em 89 candidatos**.

Carga cognitiva (COGNITIVE_LOAD). O ciclo 1 não tinha nenhuma medição direta. O ciclo 2 incorpora, com ressalvas de estrato e domínio: **P62** (fundamentos de neuroergonomia e mental workload), **P69** (WAUC — base multimodal com AUC de classificação de workload até 0,998), **P81** (experimento humano com DSS em sala de controle) e **P63** (BUS-15, instrumento de usabilidade de conversational agents — candidato a instrumento de avaliação do copilot da tese, junto com NASA-TLX usado em P69). Nenhum desses mede carga cognitiva **em resposta a incidentes de TI** — a interseção exata (copilot × IR × carga cognitiva medida) segue vazia, reforçando a RQ da dissertação.

7. Taxonomia consolidada dos paradigmas agênticos

- **LLM multi-agente:** P27, P28, P31, P35 (ciclo 1) · P76 (SOAR hyper-automation) — maduro em RCA/SOC, evidência em simulação/PoC.
- **Copilot / agente único LLM+RAG:** P34 (ciclo 1) · P78, P83, P87 (ciclo 2) — o paradigma da tese; evidência limitada a qualidade de resposta e latência, nunca MTTD/MTTR.
- **SLM / modelos compactos:** P21 (ciclo 1) — segue único; relevante para custo/confidencialidade.
- **MAS/RL e auto-organização não-LLM:** P25 (ciclo 1) · P88 (ciclo 2) — self-healing com garantias empíricas fortes (QA 4,0), lembrando que agência não implica LLM.
- **Frameworks conceituais Agentic AIOps/PdM:** P43, P82 (ciclo 2) — definem níveis de autonomia e alinhamento ITIL, sem evidência.
- **Fundacionais (surveys de agentes/LLM em segurança e operações):** P24, P33 (ciclo 1) · P52, P54, P72, P77, P79 (ciclo 2).
- **Fatores humanos:** P37 (percepção/adoção, ciclo 1) · P62, P63, P69, P81 (ciclo 2) — novo eixo do corpus.
- **Procedência a monitorar:** cluster State Grid (P31, P32, P35) no ciclo 1; NICT (P73/P80 — este excluído) no ciclo 2.

8. Rastreabilidade das exclusões

- **Ciclo 1:** P39/P40 (inelegíveis, Qualis A3); P26, P29, P30 (não-agênticos), P38 (fora de domínio) — após avaliação integral.
- **Ciclo 2 — triagem (27):** E2 não-agêntico = 19 (P41, P42, P44–P51, P64–P66, P70, P71, P75, P80, P84, P89; precedentes P26/P29/P30) · E3 fora de domínio = 8 (P56–P61, P67, P68; precedente P38) — tabelas com evidência PICOC em `triagem-ciclo2.md`.
- **Ciclo 2 — pós-avaliação (2):** P85 (SCORE_RQ 0,5 — sólido metodologicamente, sem aderência às RQs) e P86 (não-agêntico; agravante de estrato B1 + SJR Q3).

9. Confiabilidade e validação cruzada

- **Ciclo 1:** avaliação com comparação Claude × ChatGPT (concordância 90%, κ = 0,74); extração PICOC com três avaliadores (P/I/O/C 100%; Comparison κ Fleiss 0,37 → originou a regra de protocolo v1.1.0).
- **Ciclo 2:** extração PICOC e pareceres produzidos por **avaliador único** (Claude, prompts v1.3.0 com persona padronizada) — a comparação entre avaliadores do ciclo 2 está **pendente** e é o principal reforço de confiabilidade recomendado antes de fechar a síntese da dissertação.

10. Limitações e ameaças à validade

1. **Avaliador único no ciclo 2** (ver §9). 2. **Qualis derivado do percentil Scopus** (regra CAPES 2025-2028) — calibrado sem exceção nos 39 pares verificados do ciclo 1, mas não confirmado individualmente na Plataforma Sucupira para P41–P89. 3. **Emenda de protocolo (2026-09-09):** 3 incluídos fora dos estratos I3/I4 — sensibilidade da síntese a esses estudos deve ser reportada. 4. **Citações Scopus pendentes** para P41–P89 (OpenAlex/Crossref verificadas em 2026-09-09; sem chave de API). 5. **Evidência do ciclo 2 majoritariamente conceitual/PoC** — nenhuma inclusão plena; generalizações de benefício devem citar o nível de evidência da ficha de extração. 6. Exclusão temática na triagem (ciclo 2) apoiada em PICOC de leitura integral — mais forte que title/abstract, mas sem segundo avaliador.

11. Próximos passos recomendados

1. Comparação entre avaliadores do ciclo 2 (ChatGPT/Gemini) — pareceres e/ou PICOC. 2. Completar citações Scopus (nova chave de API) e, se desejado, confirmar Qualis na Sucupira para os 20 incluídos. 3. Atualizar as citações cruzadas do corpus para P01–P89. 4. Decidir formalmente o tratamento dos 7 fundacionais condicionais (corpus 53 vs. primário 46). 5. Incorporar esta síntese à dissertação, usando P76/P79/P73/P81 como âncoras da discussão de MTTD/MTTR e o cluster P62/P69/P63 como base instrumental para medir carga cognitiva no experimento da tese.

12. Nota metodológica

Protocolo idêntico ao do ciclo 1 (§13 do relatório histórico): Kitchenham et al. (2009), DARE QA1–QA4, SCORE_RQ (T/P/N → 1,0/0,5/0,0, máx. 5,0), SCORE_QA (Y/P/N, máx. 4,0), bandas Alta ≥ 3,0 / Média 1,5–2,5 / Baixa < 1,5. Diferenças do ciclo 2: (i) bibliometria verificada **antes** da avaliação (`papers-ciclo2.csv`) — Tabela A dos pareceres cita valores verificados em vez de `[VERIFICAR]`; (ii) triagem temática antecipada com evidência PICOC; (iii) prompts padronizados com persona de pesquisador orientado e Kitchenham (2009) pelo título (template); (iv) emenda de protocolo de estratos registrada e datada. Dados: `resultados-consolidados.csv` (ciclo 1) · `resultados-consolidados-ciclo2.csv` (ciclo 2) · fichas em `../report/`.

Adendo (2026-10-25) — comparação entre avaliadores do ciclo 2 concluída

A limitação nº 1 (§9/§10: avaliador único no ciclo 2) foi **sanada**: o autor executou os 22 prompts no **ChatGPT** e no **Gemini**, e a comparação entre três avaliadores foi computada em 2026-10-25. Resultado: acordo de decisão **81,8–95,5% por par** (Claude×Gemini κ = 0,65 "substancial"; Fleiss κ = 0,36 sob o mesmo paradoxo de prevalência da comparação PICOC); **as 4 divergências são todas protocolares** — 3 pela aplicação estrita do critério de estrato pelo ChatGPT (P62/P69/P81, que ignorou a emenda de 2026-09-09) e 1 pelo destino do cluster de carga cognitiva (P85) — **nenhuma de mérito**. O achado central (nenhum estudo do ciclo 2 mede MTTD/MTTR com baseline próprio) foi confirmado de forma independente pelos três avaliadores. Duas regras de protocolo a registrar pelo condutor: emendas de elegibilidade no corpo normativo dos prompts; destino dos estudos do cluster humano sem aderência às RQs.

Adendo (2026-10-26) — corpus P01–P88 com validação tripla completa

Após o adendo anterior, três marcos fecharam a validação de todo o corpus avaliado:

1. **Avaliação retroativa dos fundacionais (P01–P19):** os 19 estudos herdados do Trabalho I receberam pareceres padronizados (inclusão não rediscutida; SCORE_RQ médio 3,66 · SCORE_QA médio 2,53 · 9 Alta/10 Média) — tabela · CSV · gráficos. Com isso, **os 61 pareceres (P01–P88) usam as mesmas Tabelas 3/5/7**. 2. **Três avaliadores sobre o corpus inteiro:** ChatGPT e Gemini completaram os conjuntos P01–P88 (61 avaliações cada), consolidados por avaliador em CSVs próprios. 3. **Comparação global:** acordo de decisão **90,2–91,8% por par** · κ 0,51–0,57 · **Fleiss 0,53** · **53/61 decisões unânimes** (fundacionais 19/19; exclusões unânimes: P30, P39, P86). As **8 divergências formam 3 famílias protocolares** — (A) estudos secundários não-agênticos (P26, P29); (B) emenda de estratos de 2026-09-09 (P62, P69, P81); (C) fronteiras de domínio/estrato (P38, P40, P85) — **nenhuma de mérito**: nos 8 casos os escores dos três avaliadores convergem e o que varia é a regra aplicada à consequência.

Implicações para a síntese: (i) a seção 9 e as limitações 1 e 6 do corpo deste relatório estão **superadas** — a validação cruzada agora cobre fundacionais, ciclo 1 e ciclo 2; (ii) o corpus central da RSL (50 inclusões + 3 exclusões unânimes = 87%) é **avaliador-independente**; (iii) as 3 famílias de divergência são a lista fechada de decisões de protocolo a registrar pelo condutor (tratamento de secundários não-agênticos; posição normativa da emenda de estratos nos prompts; rigor do corte de domínio e destino do cluster de carga cognitiva); (iv) o achado central — nenhum estudo mede MTTD/MTTR nominalmente com baseline próprio em produção — permanece confirmado de forma independente pelos três avaliadores em todo o corpus. O `Papers_Index.csv` consolida por estudo o status RSL e os escores dos três avaliadores.

Adendo (2026-10-26, nº 3) — tripla checagem bibliométrica completa (Scopus)

Com a chave Scopus regenerada (mantida fora do repositório), as duas pendências bibliométricas remanescentes foram encerradas:

1. **Citações por estudo (P41–P89):** coluna Scopus completada em `papers-ciclo2.csv` — **49/49 resolvidos, todos com Citações ≥ 1, nenhum NÃO INDEXADO** (verificação de 2026-10-26). O critério I5 agora está confirmado em **três fontes para todo o corpus P01–P89**. 2. **Citações cruzadas (`citacoes-cruzadas-P01-P89.md`):** coluna Scopus preenchida via `REF()` por título — **48 arestas no Scopus, união final de 52** (era 49 com OA/CR). O Scopus agregou 3 arestas exclusivas (destaque: **P54←P06 e P54←P15**, elevando o survey "LLM Reasoning → AI Agents" a estudo citado por dois fundacionais) e confirmou os hubs P10 (7), P09 (6), P14 (5), P16 e P65 (3).

Registro metodológico: a rodada documentou dois quirks novos da Scopus Search API — **(a)** o nível de serviço da chave limita `count ≤ 25` por requisição (HTTP 400 "Exceeds the maximum number allowed for the service level" acima disso; duas varreduras completas falharam até o diagnóstico); **(b)** títulos de índice com sufixos editoriais (caso P14, "(Kshetri)") zeram silenciosamente o `REF()` — soma-se aos quirks do ciclo 1 (`REF()` por título, não DOI; forma aninhada com falso-zero). Com isso, a **limitação nº 4 do corpo deste relatório (citações Scopus pendentes) está superada** — das limitações originais, permanecem apenas as decisões de protocolo das 3 famílias de divergência (adendo nº 2) e a confirmação individual de Qualis na Sucupira, opcional.

Gerado em 2026-09-10 a partir dos artefatos versionados dos dois ciclos (adendos de 2026-10-25 e 2026-10-26 acima). Este documento consolida; os relatórios e avaliações de cada ciclo permanecem como registros históricos imutáveis.

Errata (2026-10-27)

- Na tabela comparativa dos ciclos, o **SCORE_QA médio do ciclo 2** correto é

2,73 (soma 60,0 ÷ 22 avaliados, conferida em `resultados-consolidados-ciclo2.csv`); o valor 2,75 ali exibido como média é a **mediana**. Detectado na verificação final de contagens do artigo IEEE Access (2026-10-27). O texto histórico acima não foi reescrito, conforme a convenção do repositório.

Adendo (2026-10-28, nº 4) — ciclo 3 até a avaliação parcial (Claude)

O **ciclo 3** (atualização de revisão, descoberta de 2026-10-27) avançou até a avaliação integral pelo primeiro avaliador:

1. **Funil:** 37 candidatos novos (P90–P126) → 19 elegíveis na Etapa 1 (PDR-0006 introduz o estrato de conference papers pelo percentil Scopus da série; PDR-0007 renova a emenda de estratos) → 14 com extração PICOC de leitura integral (5 capítulos Springer sem acesso, *reports not retrieved*) → triagem: **13 aprovados** · 1 excluído (E3: P108) — `triagem-ciclo3.md`. 2. **Avaliação (Claude, 13/13):** 1 Incluir (P94) · 11 Incluir c/ ressalvas · 1 Excluir (P106, E2 — "Agentic AI" nominal: ML/DRL sem LLM/arquitetura de agentes). SCORE_RQ **média 3,85 · mediana 4,0**; SCORE_QA **média 2,77 · mediana 3,0**; bandas 9 Alta · 3 Média · 1 Baixa (`resultados-consolidados-ciclo3.csv` , gráficos). 3. **Achado que altera o quadro dos ciclos 1–2:** o ciclo 3 traz o primeiro cluster de **primários com MTTD/MTTR nominal medido contra baseline executado** — P100 (AIDR-Cloud: MTTR –63% vs. SREs; MTTD p90 –83% em incidentes reais), P101 (ED-ASOC: MTTR –72,3%), P102 (Intelligent SRE: MTTD –82% vs. SREs sêniores) e P123 (CIPHER-A: MTTC –37,8%, DARPA OPTC). O achado central dos ciclos anteriores ("nenhum estudo mede MTTD/MTTR nominalmente com baseline próprio") **deixa de valer para o corpus do ciclo 3** — porém **todos os quatro estudos carregam ressalva de estrato obrigatória** (séries B2–B4/A4 ou journals A3/não indexados), o que deve qualificar qualquer síntese de benefícios. 4. **Pendências:** avaliações ChatGPT e Gemini (mesmos prompts imutáveis), consolidação tripla e comparação entre avaliadores (κ); 5 Springer via biblioteca/COMUT; snowballing (rota de recaptura do P90, nota no PDR-0006). **O corpus consolidado da RSL permanece 53** até o fecho das Etapas 7–8 com os três avaliadores.

Adendo (2026-10-29, nº 5) — ciclo 3: avaliação tripla concluída (Etapa 7)

As avaliações **ChatGPT** e **Gemini** dos 13 aprovados na triagem chegaram em 2026-10-29 (mesmos prompts imutáveis de `prompts/prompt-PXX.md`, template v1.1.0), fechando a consolidação da Etapa 7 com os três

avaliadores independentes:

Avaliador	SCORE_RQ média (mediana)	SCORE_QA média (mediana)	Bandas (Alta·Média·Baixa)	Recomendações
Claude	3,85 (4,0)	2,77 (3,0)	9 · 3 · 1	1 Incluir · 11 c/ ressalvas · 1 Excluir
ChatGPT	4,12 (4,0)	2,69 (2,5)	5 · 8 · 0	12 Incluir c/ ressalvas · 1 Excluir
Gemini	3,77 (4,0)	2,92 (3,0)	9 · 3 · 1	1 Incluir · 11 c/ ressalvas · 1 Excluir

Leituras principais (fonte: `resultados-consolidados-ciclo3.csv` + `Papers_Index.csv`, escores dos três avaliadores):

1. **Unanimidade no colapso Incluir/Excluir:** os três avaliadores convergem nos 13 estudos — 12 Incluir (P94 pleno por Claude e Gemini; com ressalvas pelo ChatGPT) e **1 Excluir (P106, E2 — agência nominal, DRL/CNN sem Agentic AI)**, confirmando o flag da triagem. O κ formal por par, o Fleiss e a análise de divergências de escore são da Etapa 8. 2. **O cluster MTTD/MTTR nominal sobrevive aos três avaliadores:** P100, P101, P102 e P123 mantêm recomendação de inclusão pelos três, sempre com a **ressalva de estrato obrigatória** (PDR-0006/0007) — o achado do adendo nº 4 permanece, agora com validação tripla. 3. **Divergências de intensidade, não de decisão:** o ChatGPT pontua RQ mais alto (média 4,12) e QA mais baixo (mediana 2,5; 5 bandas Alta contra 9 de Claude/Gemini), refletindo rubrica QA "operacional provisória" declarada nos próprios pareceres; Gemini e Claude praticamente coincidem nas bandas (9·3·1). Nenhuma divergência atinge o colapso de decisão. 4. **Próximos passos:** comparação entre avaliadores (Etapa 8 — κ de Cohen por par, Fleiss, prevalência) e fichas de extração (Etapa 9); só então o corpus consolidado (hoje **53**) incorpora o ciclo 3. Permanecem as pendências dos 5 Springer (biblioteca/COMUT) e do snowballing (P90).

Adendo (2026-10-29, nº 6) — ciclo 3: comparação entre avaliadores (Etapa 8) e fecho do ciclo

A comparação formal dos três avaliadores sobre os 13 estudos do ciclo 3 (`scripts/compute-kappa.py`, decisão colapsada Incluir/Excluir) fecha a Etapa 8 com resultado inédito nos três ciclos:

Métrica	Claude × ChatGPT	Claude × Gemini	ChatGPT × Gemini
Acordo	100% (13/13)	100% (13/13)	100% (13/13)
Cohen's κ	1,00	1,00	1,00
MAE SCORE_RQ / SCORE_QA	0,42 / 0,31	0,38 / 0,23	0,50 / 0,54

Fleiss' κ = 1,00 · 13/13 unânimes · prevalência de Incluir 92,3% — *almost perfect* (Landis & Koch), sem a deflação do paradoxo da prevalência dos ciclos 1–2 porque não há desacordo algum a penalizar. Leituras:

1. **Nenhuma divergência protocolar ou de mérito; nenhum PDR novo.** A exclusão do P106 (E2 — Agentic AI nominal) é unânime e confirma o flag da triagem com evidência PICOC. 2. **A lição protocolar do ciclo 2 está verificada:** com as emendas PDR-0006/0007 injetadas no texto normativo dos prompts pelo render (regra R2/PDR-0004), o ChatGPT avaliou todos os fora-de-estrato com ressalva (zero `NA`), em vez de encerrá-los na triagem como fez com P62/P69/P81 no ciclo 2. 3. **Diferenças restantes são de intensidade:** rubrica QA do ChatGPT mais conservadora (5 bandas Alta vs. 9; acordo de banda 62%); Claude × Gemini com bandas idênticas (13/13) e menores MAEs — detalhes em `comparacao-avaliadores-ciclo3.md`. 4. **Corpus consolidado: 53 → 65.** Com a Etapa 8 fechada, o ciclo 3 incorpora seus 12 incluídos (P91, P93,

P94, P97, P100, P101, P102, P110, P112, P119, P121, P123 — todos com ressalva de estrato obrigatória, PDR-0006/0007, exceto a dimensão fundacional-condicional R1 de P110/P112/P121). O cluster MTTD/MTTR nominal (P100/P101/P102/P123) entra no corpus com validação tripla. Pendências que podem alterar o corpus em adendos futuros: 5 capítulos Springer adiados (biblioteca/COMUT), snowballing obrigatório (rota de recaptura do P90) e fichas de extração (Etapa 9).