

Relatório de Síntese — RSL "Agentic AI Copilot para Resposta a Incidentes"

Lote avaliado: estudos candidatos **P20–P40** (20 estudos; P36 era duplicata de P31/LEMAD, removida).
Fonte: [resultados-consolidados.csv](#) + pareceres individuais [review-Pxx.md](#). **Método de avaliação:** prompt por estudo (`../prompts/`) executado contra o PDF (`../docs/`), seguindo Kitchenham et al. (2009) e a lógica DARE (QA1–QA4). Vereditos de RQ em T/P/N (1,0 / 0,5 / 0,0) e QA em Y/P/N.

⚠ Ressalva transversal: Citações, SJR e Qualis **não são verificáveis nos PDFs**. Todos os valores de Qualis/SJR vêm dos **insumos** do CSV e permanecem **pendentes de verificação externa** (Scimago; Plataforma Sucupira/Qualis CAPES; base indexadora).

1. Resumo executivo


- **20 estudos** processados; **18 avaliados integralmente**; **2 inelegíveis** na triagem (P39, P40 — **Qualis A3 < A1–A2**).
- **Aderência geral alta:** SCORE_RQ médio **3,83/5,0** (mediana 4,0); SCORE_QA médio **3,50/4,0** (mediana 3,75). **14 de 18 em Banda Alta**, 4 em Média, nenhum em Baixa.
- **Decisão de inclusão:** **14 Incluir** (7 plenos + 5 com ressalvas + 2 fundacionais), **4 Excluir** por relevância/tipo/domínio, **2 Inelegíveis**.
- **Eixo organizador das decisões:** *agêntico × domínio-IR*. Incluídos são **agênticos** e próximos de IR/AIOps/SOC; exclusões recaem em não-agênticos, off-domain ou inelegíveis.
- **Lacuna sistemática identificada:** **RQ4 (Desafios & Ética)** é a questão menos coberta — apenas **4/18** plenamente respondidas; **14/18 parciais**. Ética/governança é o ponto fraco recorrente dos estudos técnicos de sistema.

2. Funil de elegibilidade (ETAPA 1)

Etapa	Qtde	IDs
Candidatos recebidos	20	P20–P40 (P36 já removido)
Inelegíveis (Qualis A3)	2	P39, P40
Elegíveis (avaliados)	18	demais
→ Incluídos (qualquer forma)	14	P20–P25, P27, P28, P31–P35, P37
→ Excluídos por relevância/tipo/domínio	4	P26, P29, P30, P38

Critérios verificáveis no PDF (Ano ≥ 2020; veículo ≠ NULL) **atendidos por todos**. Os critérios **Citações ≥ 1, SJR Q1–Q2 e Qualis A1–A2** ficam **pendentes** — exceto Qualis A3 de P39/P40 (insumo), que motiva a inelegibilidade.

Distribuição das recomendações (20 estudos)




3. Cobertura por questão de pesquisa (RQ)

Distribuição de vereditos entre os 18 estudos avaliados:

RQ	Tema	T (1,0)	P (0,5)	N (0,0)	Leitura
RQ1	Context Definitions (autonomia, planejamento, memória, ferramentas, supervisão)	9	6	3	Boa, mas heterogênea: 3 estudos sem conteúdo agêntico (N)
RQ2	Engineering Architecture (orquestração, memória, guardrails, observabilidade)	11	6	1	Forte — núcleo dos estudos de sistema
RQ3	Evidence Benefits (métricas, tempo de resposta, qualidade de decisão)	12	6	0	Mais coberta — evidência empírica abundante
RQ4	Challenges & Ethics (segurança, robustez, governança, accountability)	4	14	0	Lacuna sistemática — ética/governança rasa
RQ5	Research Gaps (avaliação, threat models, governança, observabilidade)	16	2	0	Quase universal — direções futuras bem articuladas

Cobertura por RQ (18 estudos avaliados)




Achados-chave:

- **RQ3 e RQ5 são os pontos fortes** do corpus: os estudos reportam métricas (F1, MTTD/MTTR, latência, acurácia de localização) e propõem direções futuras de forma consistente.
- **RQ4 é o gargalo.** Apenas **P24, P33, P34, P37** respondem RQ4 plenamente — justamente os estudos **conceituais/governança/humano-organizacionais**. Os **sistemas agênticos técnicos** (P21–P23, P25, P27, P28, P31, P32, P35) recebem majoritariamente **P** por discutirem desafios técnicos mas **omitirem ética/governança/accountability** — notável dado que vários atuam em **infraestrutura crítica** (rede elétrica: P31, P32, P35) ou têm **caráter dual-use** (P25 ofensivo).
- **RQ1 (N=3):** os três sem conteúdo agêntico são **P26** (survey de RCA), **P29** (SLR) e **P30** (pipeline LLM) — coerente com suas exclusões.

4. Avaliação de qualidade (QA / DARE)


Critério	Y	P	N	Observação
QA1 Objetivos claros	18	0	0	Universal — todos enunciam problema/objetivos
QA2 Metodologia replicável	11	7	0	7 parciais: dados proprietários / sem código / prompts não publicados (P20, P26, P28, P29, P31, P32, P33)
QA3 Base de evidências sólida	13	1	4	4 N = estudos secundários sem validação empírica própria (P24, P26, P29, P33)
QA4 Conclusões coerentes	16	2	0	2 parciais (P23, P26): limitações pouco discutidas

Qualidade (QA/DARE) — 18 estudos avaliados



- **Banda de qualidade:** **14 Alta** ($\geq 3,0$) · **4 Média** (1,5–2,5) · **0 Baixa**. As 4 Médias são **P24, P26, P29, P33** — todos **secundários** (QA3 = N puxa o escore).
- **Reprodutibilidade (QA2)** é o calcanhar recorrente dos estudos primários: **dados de produção proprietários** (SGCC em P31/P32/P35; SpamAssassin/custom em P28) e **ausência de repositórios de código/prompts** limitam a replicação plena. Exceções positivas: P35 (templates de prompt no apêndice), P38 (base pública + métricas definidas), P34/P37 (protocolos detalhados).

5. Ranking de aderência (SCORE_RQ + SCORE_QA)




Pos.	ID	SCORE_RQ	SCORE_QA	Σ	Recomendação
1	P21	4,5	4,0	8,5	Incluir
1	P22	4,5	4,0	8,5	Incluir
1	P25	4,5	4,0	8,5	Incluir
1	P27	4,5	4,0	8,5	Incluir
5	P28	4,5	3,5	8,0	Incluir
5	P31	4,5	3,5	8,0	Incluir
5	P34	4,0	4,0	8,0	Incluir c/ ressalvas
5	P35	4,0	4,0	8,0	Incluir
9	P32	4,0	3,5	7,5	Incluir c/ ressalvas
9	P38	3,5	4,0	7,5	Excluir (domínio)
11	P20	4,0	3,0	7,0	Incluir c/ ressalvas
11	P23	3,5	3,5	7,0	Incluir c/ ressalvas
11	P30	3,0	4,0	7,0	Excluir (tipo)
11	P37	3,0	4,0	7,0	Incluir c/ ressalvas
15	P24	4,0	2,5	6,5	Incluir c/ ressalvas (fund.)
15	P33	4,0	2,5	6,5	Incluir c/ ressalvas (fund.)
17	P26	2,5	2,5	5,0	Excluir
17	P29	2,5	2,5	5,0	Excluir

Nota: a pontuação **não substitui** a decisão de relevância. P38 e P30 pontuam alto (Σ 7,5 e 7,0) mas são **excluídos** por domínio/tipo — escore alto ≠ aderência ao escopo da RSL.

Núcleo recomendado (top tier): P21, P22, P25, P27, P28, P31, P35 — sistemas agênticos, IR/AIOps/SOC, evidência empírica robusta. **P34** complementa pelo lado *copilot/IR puro* (NIST 800-61).

O mapa abaixo cruza os dois escores: o quadrante superior-direito (SCORE_RQ ≥ 4,0 e SCORE_QA ≥ 3,5) concentra o núcleo de inclusão; exclusões por tipo/domínio (P30, P38) aparecem com alta qualidade mas fora do escopo, e os secundários (P24, P33, P26, P29) caem na faixa de QA ≤ 2,5.



6. Taxonomia do corpus incluído

Por paradigma de agente (eixo a registrar no mapeamento, pois afeta comparabilidade):

Paradigma	Estudos
LLM multi-agente (orquestrador + especializados)	P27, P28, P31, P35
LLM-agente closed-loop (sense→act autônomo)	P22
SLM-agente (modelos pequenos, on-prem)	P21
LLM + GNN / tools (agente sobre núcleo DL)	P23, P32
LLM+RAG multiagente	P20
MAS/RL não-LLM (RL/ML, IR baseado em regras)	P25
LLM copilot / baixa autonomia	P34
Survey de percepção (lado da demanda)	P37
Survey/Review agêntico (fundacional)	P24, P33

Por domínio: RCA/diagnóstico (P23, P27, P32, P35) · AIOps/operações (P21, P31) · SOC/detecção & IR de segurança (P25, P28, P34, P37) · remediação (P22) · prevenção IaC (P20) · fundamentação (P24, P33).

Espectro de autonomia (útil para a discussão): **remediação autônoma closed-loop (P22)** → **multi-agente RCA com validação adversarial (P27/P35)** → **GNN+agente de recuperação offline (P32)** → **copilot humano-no-loop (P34)** → **percepção de adoção/confiança (P37)**.

7. Achados transversais e implicações para a RSL

1. **A maturidade está na arquitetura e na evidência (RQ2/RQ3), não na governança (RQ4).** O campo entrega sistemas agênticos funcionais e bem medidos, mas **subtrata ética, accountability e governança** — gap a destacar como contribuição/lacuna da RSL, sobretudo para infraestrutura crítica e usos dual-use. 2. **Convergência forte em RCA/AIOps.** Metade dos incluídos ataca **localização de causa raiz** (P23, P27, P32, P35) — sinal de sub-tarefa madura do IR; a **remediação autônoma** (P22) e a **detecção/correlação em SOC** (P28) são menos povoadas, indicando frente promissora. 3. **Dois paradigmas concorrentes de "agente":** LLM-agêntico (maioria) vs **MAS/RL não-LLM** (P25) — comparáveis em desempenho de IR, mas distintos em autonomia/explicabilidade; e o extremo **copilot** (P34) alinhado ao próprio título da RSL. 4. **Procedência concentrada:** P31, P32, P35 vêm de equipes ligadas à **State Grid (China)** — registrar ao analisar independência/viés do corpus. 5. **Risco temporal de elegibilidade: 5 estudos de 2026** (P25, P30, P32, P35, P37) podem ter **0 citações** — o critério "Citações ≥ 1" deve ser verificado antes de confirmar inclusão (pode reclassificar P30/P32/P35/P37).

8. Decisões de exclusão (rastreadibilidade)

ID	Motivo	Natureza
P26	Secundário (survey de RCA) e não-agêntico (RQ1=N)	Relevância/tipo
P29	Secundário (SLR) e não-agêntico (RQ1=N)	Relevância/tipo
P30	Não-agêntico (pipeline LLM; RQ1=N) + domínio bug-triage de inference engines	Relevância/tipo
P38	Agêntico, alta qualidade, mas domínio agricultura (0 menções a IR)	Domínio
P39	Qualis A3 (< A1–A2) + artigo de opinião (não-empírico)	Inelegível (ETAPA 1)
P40	Qualis A3 (< A1–A2) + survey secundário não-agêntico	Inelegível (ETAPA 1)


Estudos fundacionais (P24, P33): incluídos **com ressalva** — se o protocolo restringir o corpus primário a **estudos primários**, migram para a **fundamentação**, resultando em **12 estudos no corpus primário**.

9. Confiabilidade entre avaliadores (Claude × ChatGPT)

Os 20 estudos foram avaliados **independentemente** por dois avaliadores (Claude e ChatGPT) sob o mesmo protocolo. A concordância é **substancial**, o que reforça a robustez dos vereditos:

- **Decisão (Incluir/Excluir): 90% (18/20) · Cohen's κ = 0,74.**
- **Banda de qualidade: 100% (18/18) · erro absoluto médio SCORE_RQ 0,42 / SCORE_QA 0,31.**
- **RQ4 e RQ5: 100% de acordo** — ambos os avaliadores confirmam, de forma independente, a **lacuna sistemática de ética/governança (RQ4)**, tornando esse achado avaliador-robusto.
- Únicas 2 divergências de decisão: **P26 e P29** (surveys/SLR não-agênticos) — o ChatGPT inclui com ressalvas; o Claude exclui. Reforça que o único ponto de protocolo em aberto é o **tratamento de estudos secundários**.

Concordância entre avaliadores — Claude x ChatGPT (20 estudos)



Cohen's κ (decisão) = 0.74 · erro abs. médio SCORE_RQ = 0.42 · SCORE_QA = 0.31

Detalhes e tabela lado a lado: [comparacao-avaliadores.md](#) · dados em [comparacao-avaliadores.csv](#).

10. Limitações desta avaliação

- **Extração de texto via PDFKit** (sem renderização de página): tabelas/figuras com layout complexo podem ter perdido valores tabulares — vereditos ancorados no texto corrido e nas tabelas legíveis.
- **Qualis/SJR/Citações não confirmados** (insumos): toda decisão de elegibilidade dependente desses itens é **provisória**.
- **Julgamento de relevância** (agêntico × IR) é interpretativo; casos-limite (P30, P34, P37, P38) foram explicitados nos pareceres individuais para auditabilidade.

11. Próximos passos recomendados

1. **Verificar externamente** Citações/SJR/Qualis dos 18 elegíveis (atenção a P30/P32/P35/P37 — 2026, possível 0 citações; e confirmar A3 de P39/P40). 2. **Decidir no protocolo** o tratamento de estudos secundários (P24, P33): corpus primário vs fundamentação. 3. **Anexar os escores** às Tabelas 3, 5 e 7 da RSL existente (IDs já sequenciais a partir de P20). 4. **Destacar a lacuna de RQ4** (ética/governança) como achado/contribuição da revisão. 5. **Registrar o eixo de paradigma de agente** (Seção 6) no mapeamento, para comparabilidade entre LLM-agêntico, MAS/RL e copilot.

_Gerado a partir de [reviews/resultados-consolidados.csv](#) (20 estudos). Estatísticas: SCORE_RQ médio 3,83; SCORE_QA médio 3,50; 14 Banda Alta; RQ4 plenamente respondida em apenas 4/18._