

Relatório de Síntese — RSL "Agentic AI Copilot para Resposta a Incidentes"

Lote avaliado: estudos candidatos **P20–P40** (20 estudos; P36 era duplicata de P31/LEMAD, removida).
Fonte: [resultados-consolidados.csv](#) + pareceres individuais [review-Pxx.md](#). **Método de avaliação:** prompt por estudo (`../prompts/`) executado contra o PDF (`../docs/`), seguindo Kitchenham et al. (2009) e a lógica DARE (QA1–QA4). Vereditos de RQ em T/P/N (1,0 / 0,5 / 0,0) e QA em Y/P/N.

⚠ Ressalva transversal: Citações, SJR e Qualis **não são verificáveis nos PDFs**. Todos os valores de Qualis/SJR vêm dos **insumos** do CSV e permanecem **pendentes de verificação externa** (Scimago; Plataforma Sucupira/Qualis CAPES; base indexadora).

1. Resumo executivo


- **20 estudos** processados; **18 avaliados integralmente**; **2 inelegíveis** na triagem (P39, P40 — **Qualis A3 < A1–A2**).
- **Aderência geral alta:** SCORE_RQ médio **3,83/5,0** (mediana 4,0); SCORE_QA médio **3,50/4,0** (mediana 3,75). **14 de 18 em Banda Alta**, 4 em Média, nenhum em Baixa.
- **Decisão de inclusão:** **14 Incluir** (7 plenos + 5 com ressalvas + 2 fundacionais), **4 Excluir** por relevância/tipo/domínio, **2 Inelegíveis**.
- **Eixo organizador das decisões:** *agêntico × domínio-IR*. Incluídos são **agênticos** e próximos de IR/AIOps/SOC; exclusões recaem em não-agênticos, off-domain ou inelegíveis.
- **Lacuna sistemática identificada:** **RQ4 (Desafios & Ética)** é a questão menos coberta — apenas **4/18** plenamente respondidas; **14/18 parciais**. Ética/governança é o ponto fraco recorrente dos estudos técnicos de sistema.

2. Funil de elegibilidade (ETAPA 1)

Etapa	Qtde	IDs
Candidatos recebidos	20	P20–P40 (P36 já removido)
Inelegíveis (Qualis A3)	2	P39, P40
Elegíveis (avaliados)	18	demais
→ Incluídos (qualquer forma)	14	P20–P25, P27, P28, P31–P35, P37
→ Excluídos por relevância/tipo/domínio	4	P26, P29, P30, P38

Critérios verificáveis no PDF (Ano ≥ 2020; veículo ≠ NULL) **atendidos por todos**. Os critérios **Citações ≥ 1, SJR Q1–Q2 e Qualis A1–A2** ficam **pendentes** — exceto Qualis A3 de P39/P40 (insumo), que motiva a inelegibilidade.

Distribuição das recomendações (20 estudos)




3. Cobertura por questão de pesquisa (RQ)

Distribuição de vereditos entre os 18 estudos avaliados:

RQ	Tema	T (1,0)	P (0,5)	N (0,0)	Leitura
RQ1	Context Definitions (autonomia, planejamento, memória, ferramentas, supervisão)	9	6	3	Boa, mas heterogênea: 3 estudos sem conteúdo agêntico (N)
RQ2	Engineering Architecture (orquestração, memória, guardrails, observabilidade)	11	6	1	Forte — núcleo dos estudos de sistema
RQ3	Evidence Benefits (métricas, tempo de resposta, qualidade de decisão)	12	6	0	Mais coberta — evidência empírica abundante
RQ4	Challenges & Ethics (segurança, robustez, governança, accountability)	4	14	0	Lacuna sistemática — ética/governança rasa
RQ5	Research Gaps (avaliação, threat models, governança, observabilidade)	16	2	0	Quase universal — direções futuras bem articuladas

Cobertura por RQ (18 estudos avaliados)




Achados-chave:

- **RQ3 e RQ5 são os pontos fortes** do corpus: os estudos reportam métricas (F1, MTTD/MTTR, latência, acurácia de localização) e propõem direções futuras de forma consistente.
- **RQ4 é o gargalo.** Apenas **P24, P33, P34, P37** respondem RQ4 plenamente — justamente os estudos **conceituais/governança/humano-organizacionais**. Os **sistemas agênticos técnicos** (P21–P23, P25, P27, P28, P31, P32, P35) recebem majoritariamente **P** por discutirem desafios técnicos mas **omitirem ética/governança/accountability** — notável dado que vários atuam em **infraestrutura crítica** (rede elétrica: P31, P32, P35) ou têm **caráter dual-use** (P25 ofensivo).
- **RQ1 (N=3):** os três sem conteúdo agêntico são **P26** (survey de RCA), **P29** (SLR) e **P30** (pipeline LLM) — coerente com suas exclusões.

4. Avaliação de qualidade (QA / DARE)


Critério	Y	P	N	Observação
QA1 Objetivos claros	18	0	0	Universal — todos enunciam problema/objetivos
QA2 Metodologia replicável	11	7	0	7 parciais: dados proprietários / sem código / prompts não publicados (P20, P26, P28, P29, P31, P32, P33)
QA3 Base de evidências sólida	13	1	4	4 N = estudos secundários sem validação empírica própria (P24, P26, P29, P33)
QA4 Conclusões coerentes	16	2	0	2 parciais (P23, P26): limitações pouco discutidas

Qualidade (QA/DARE) — 18 estudos avaliados



- **Banda de qualidade:** 14 Alta ($\geq 3,0$) · 4 Média (1,5–2,5) · 0 Baixa. As 4 Médias são **P24, P26, P29, P33** — todos **secundários** (QA3 = N puxa o escore).
- **Reprodutibilidade (QA2)** é o calcanhar recorrente dos estudos primários: **dados de produção proprietários** (SGCC em P31/P32/P35; SpamAssassin/custom em P28) e **ausência de repositórios de código/prompts** limitam a replicação plena. Exceções positivas: P35 (templates de prompt no apêndice), P38 (base pública + métricas definidas), P34/P37 (protocolos detalhados).

5. Ranking de aderência (SCORE_RQ + SCORE_QA)




Pos.	ID	SCORE_RQ	SCORE_QA	Σ	Recomendação
1	P21	4,5	4,0	8,5	Incluir
1	P22	4,5	4,0	8,5	Incluir
1	P25	4,5	4,0	8,5	Incluir
1	P27	4,5	4,0	8,5	Incluir
5	P28	4,5	3,5	8,0	Incluir
5	P31	4,5	3,5	8,0	Incluir
5	P34	4,0	4,0	8,0	Incluir c/ ressalvas
5	P35	4,0	4,0	8,0	Incluir
9	P32	4,0	3,5	7,5	Incluir c/ ressalvas
9	P38	3,5	4,0	7,5	Excluir (domínio)
11	P20	4,0	3,0	7,0	Incluir c/ ressalvas
11	P23	3,5	3,5	7,0	Incluir c/ ressalvas
11	P30	3,0	4,0	7,0	Excluir (tipo)
11	P37	3,0	4,0	7,0	Incluir c/ ressalvas
15	P24	4,0	2,5	6,5	Incluir c/ ressalvas (fund.)
15	P33	4,0	2,5	6,5	Incluir c/ ressalvas (fund.)
17	P26	2,5	2,5	5,0	Excluir
17	P29	2,5	2,5	5,0	Excluir

Nota: a pontuação **não substitui** a decisão de relevância. P38 e P30 pontuam alto (Σ 7,5 e 7,0) mas são **excluídos** por domínio/tipo — escore alto ≠ aderência ao escopo da RSL.

Núcleo recomendado (top tier): P21, P22, P25, P27, P28, P31, P35 — sistemas agênticos, IR/AIOps/SOC, evidência empírica robusta. **P34** complementa pelo lado *copilot/IR puro* (NIST 800-61).

O mapa abaixo cruza os dois escores: o quadrante superior-direito (SCORE_RQ ≥ 4,0 e SCORE_QA ≥ 3,5) concentra o núcleo de inclusão; exclusões por tipo/domínio (P30, P38) aparecem com alta qualidade mas fora do escopo, e os secundários (P24, P33, P26, P29) caem na faixa de QA ≤ 2,5.



6. Taxonomia do corpus incluído

Por paradigma de agente (eixo a registrar no mapeamento, pois afeta comparabilidade):

Paradigma	Estudos
LLM multi-agente (orquestrador + especializados)	P27, P28, P31, P35
LLM-agente closed-loop (sense→act autônomo)	P22
SLM-agente (modelos pequenos, on-prem)	P21
LLM + GNN / tools (agente sobre núcleo DL)	P23, P32
LLM+RAG multiagente	P20
MAS/RL não-LLM (RL/ML, IR baseado em regras)	P25
LLM copilot / baixa autonomia	P34
Survey de percepção (lado da demanda)	P37
Survey/Review agêntico (fundacional)	P24, P33

Por domínio: RCA/diagnóstico (P23, P27, P32, P35) · AIOps/operações (P21, P31) · SOC/detecção & IR de segurança (P25, P28, P34, P37) · remediação (P22) · prevenção IaC (P20) · fundamentação (P24, P33).

Espectro de autonomia (útil para a discussão): **remediação autônoma closed-loop (P22)** → **multi-agente RCA com validação adversarial (P27/P35)** → **GNN+agente de recuperação offline (P32)** → **copilot humano-no-loop (P34)** → **percepção de adoção/confiança (P37)**.

7. Achados transversais e implicações para a RSL

1. **A maturidade está na arquitetura e na evidência (RQ2/RQ3), não na governança (RQ4).** O campo entrega sistemas agênticos funcionais e bem medidos, mas **subtrata ética, accountability e governança** — gap a destacar como contribuição/lacuna da RSL, sobretudo para infraestrutura crítica e usos dual-use. 2. **Convergência forte em RCA/AIOps.** Metade dos incluídos ataca **localização de causa raiz** (P23, P27, P32, P35) — sinal de sub-tarefa madura do IR; a **remediação autônoma** (P22) e a **detecção/correlação em SOC** (P28) são menos povoadas, indicando frente promissora. 3. **Dois paradigmas concorrentes de "agente":** LLM-agêntico (maioria) vs **MAS/RL não-LLM** (P25) — comparáveis em desempenho de IR, mas distintos em autonomia/explicabilidade; e o extremo **copilot** (P34) alinhado ao próprio título da RSL. 4. **Procedência concentrada:** P31, P32, P35 vêm de equipes ligadas à **State Grid (China)** — registrar ao analisar independência/viés do corpus. 5. **Risco temporal de elegibilidade: 5 estudos de 2026** (P25, P30, P32, P35, P37) podem ter **0 citações** — o critério "Citações ≥ 1" deve ser verificado antes de confirmar inclusão (pode reclassificar P30/P32/P35/P37).

8. Decisões de exclusão (rastreadibilidade)

ID	Motivo	Natureza
P26	Secundário (survey de RCA) e não-agêntico (RQ1=N)	Relevância/tipo
P29	Secundário (SLR) e não-agêntico (RQ1=N)	Relevância/tipo
P30	Não-agêntico (pipeline LLM; RQ1=N) + domínio bug-triage de inference engines	Relevância/tipo
P38	Agêntico, alta qualidade, mas domínio agricultura (0 menções a IR)	Domínio
P39	Qualis A3 (< A1–A2) + artigo de opinião (não-empírico)	Inelegível (ETAPA 1)
P40	Qualis A3 (< A1–A2) + survey secundário não-agêntico	Inelegível (ETAPA 1)


Estudos fundacionais (P24, P33): incluídos **com ressalva** — se o protocolo restringir o corpus primário a **estudos primários**, migram para a **fundamentação**, resultando em **12 estudos no corpus primário**.

9. Confiabilidade entre avaliadores (Claude × ChatGPT)

Os 20 estudos foram avaliados **independentemente** por dois avaliadores (Claude e ChatGPT) sob o mesmo protocolo. A concordância é **substancial**, o que reforça a robustez dos vereditos:

- **Decisão (Incluir/Excluir): 90% (18/20) · Cohen's κ = 0,74.**
- **Banda de qualidade: 100% (18/18) · erro absoluto médio SCORE_RQ 0,42 / SCORE_QA 0,31.**
- **RQ4 e RQ5: 100% de acordo** — ambos os avaliadores confirmam, de forma independente, a **lacuna sistemática de ética/governança (RQ4)**, tornando esse achado avaliador-robusto.
- **Únicas 2 divergências de decisão: P26 e P29** (surveys/SLR não-agênticos) — o ChatGPT inclui com ressalvas; o Claude exclui. Reforça que o único ponto de protocolo em aberto é o **tratamento de estudos secundários**.

Concordância entre avaliadores — Claude x ChatGPT (20 estudos)



Cohen's κ (decisão) = 0.74 · erro abs. médio SCORE_RQ = 0.42 · SCORE_QA = 0.31

Detalhes e tabela lado a lado: [comparacao-avaliadores.md](#) · dados em [comparacao-avaliadores.csv](#).

10. Limitações desta avaliação

- **Extração de texto via PDFKit** (sem renderização de página): tabelas/figuras com layout complexo podem ter perdido valores tabulares — vereditos ancorados no texto corrido e nas tabelas legíveis.
- **Qualis/SJR/Citações não confirmados** (insumos): toda decisão de elegibilidade dependente desses itens é **provisória**.
- **Julgamento de relevância** (agêntico × IR) é interpretativo; casos-limite (P30, P34, P37, P38) foram explicitados nos pareceres individuais para auditabilidade.

11. Próximos passos recomendados

1. **Verificar externamente** Citações/SJR/Qualis dos 18 elegíveis (atenção a P30/P32/P35/P37 — 2026, possível 0 citações; e confirmar A3 de P39/P40). 2. **Decidir no protocolo** o tratamento de estudos secundários (P24, P33): corpus primário vs fundamentação. 3. **Anexar os escores** às Tabelas 3, 5 e 7 da RSL existente (IDs já sequenciais a partir de P20). 4. **Destacar a lacuna de RQ4** (ética/governança) como achado/contribuição da revisão. 5. **Registrar o eixo de paradigma de agente** (Seção 6) no mapeamento, para comparabilidade entre LLM-agêntico, MAS/RL e copilot.

12. Nota metodológica (métodos e métricas)

Esta seção descreve, de forma reprodutível, **como** os números deste relatório e da [comparação entre avaliadores](#) foram obtidos.

12.1 Protocolo de avaliação (Kitchenham + DARE)

Cada estudo foi avaliado seguindo as diretrizes de **Kitchenham et al. (2009)** para RSL em Engenharia de Software, com a avaliação de qualidade espelhando a lógica dos critérios **DARE (QA1–QA4)**. O fluxo por estudo: triagem de elegibilidade (PRISMA/ETAPA 1) → classificação das 5 RQs → avaliação de qualidade (4 QAs) → parecer (Incluir / Incluir com ressalvas / Excluir).

12.2 Pontuação das RQs (SCORE_RQ)

Cada RQ recebe um veredito ancorado em evidência do PDF, convertido em escore:

Símbolo	Veredito	Valor
T	Respondida Plenamente (todas as subdimensões com conteúdo explícito)	1,0
P	Parcialmente Respondida (≥1 subdimensão, ou cobertura genérica)	0,5
N	Sem conteúdo suficiente (ausente ou apenas tangencial)	0,0

SCORE_RQ = soma dos 5 vereditos (máximo 5,0).

12.3 Avaliação de qualidade (SCORE_QA e banda)

Quatro critérios DARE — QA1 (objetivos claros), QA2 (metodologia replicável), QA3 (base de evidências sólida; *toy example* = P, teórico = N), QA4 (conclusões coerentes) — pontuados **Y = 1,0 / P = 0,5 / N = 0,0**.

SCORE_QA = soma (máximo 4,0). **Banda de qualidade:** Alta ≥ 3,0 · Média 1,5–2,5 · Baixa < 1,5.

12.4 Triagem de elegibilidade (ETAPA 1 / PRISMA)

Critérios de inclusão: Ano ≥ 2020; veículo identificável; **Citações ≥ 1**; **SJR Q1–Q2**; **Qualis A1–A2**. Os três últimos não são verificáveis no PDF → marcados [VERIFICAR]. Estudos com Qualis A3 informado (P39, P40) foram tratados como **inelegíveis** (encerramento na triagem).

12.5 Estatística descritiva

- **Média / mediana** de SCORE_RQ e SCORE_QA sobre os 18 estudos avaliados (P39/P40 excluídos por serem NA).
- Distribuição de bandas e de vereditos T/P/N por RQ (contagens simples).

12.6 Concordância entre avaliadores

Compara os vereditos **independentes** de dois avaliadores (Claude e ChatGPT) sobre o mesmo protocolo. Métricas:

(a) Acordo observado (P_o) — proporção de estudos em que os dois concordam:

$$P_o = (\text{nº de concordâncias}) \div N$$

Aqui, decisão Incluir/Excluir: $P_o = 18/20 = 0,90$ (90%).

(b) Cohen's κ (kappa) — corrige o acordo observado pelo **acordo esperado ao acaso (P_e)**, dado o quanto cada avaliador usa cada categoria. É a medida-padrão de *inter-rater reliability* para classificações categóricas:

$$\kappa = (P_o - P_e) / (1 - P_e), \text{ com } P_e = \sum_i (n_{\text{Claude},i} \times n_{\text{ChatGPT},i}) / N^2$$

Por que usar κ e não só o % de acordo? Porque dois avaliadores que dão "Incluir" com frequência concordariam bastante **por acaso**; κ desconta esse acaso. $\kappa = 1$ é acordo perfeito; $\kappa = 0$ é igual ao acaso; $\kappa < 0$ é pior que o acaso.

Cálculo neste lote (decisão binária, $N = 20$):

- Marginais: Claude → 14 Incluir / 6 Excluir; ChatGPT → 16 Incluir / 4 Excluir.
- Acordo esperado: $P_e = (14 \times 16 + 6 \times 4) / 20^2 = 248 / 400 = 0,62$.
- $\kappa = (0,90 - 0,62) / (1 - 0,62) = 0,28 / 0,38 = 0,737$.

Interpretação (escala de Landis & Koch, 1977):

κ	Força da concordância
< 0,00	Pobre (pior que o acaso)
0,00–0,20	Leve
0,21–0,40	Razoável
0,41–0,60	Moderada
0,61–0,80	Substancial ← $\kappa = 0,74$ (este lote)
0,81–1,00	Quase perfeita

(c) Erro absoluto médio (MAE) dos escores — magnitude típica da diferença numérica entre avaliadores:

$$MAE = (1/n) \cdot \sum |SCORE_ChatGPT - SCORE_Claude|$$

Resultados: $MAE(SCORE_RQ) = 0,42$; $MAE(SCORE_QA) = 0,31$ ($n = 18$; P39/P40 excluídos por NA).

(d) Acordo exato por RQ — proporção de estudos em que o símbolo T/P/N coincide, por RQ (RQ1 67% ... RQ4/RQ5 100%).

Limitações da comparação: $N = 20$ é pequeno (κ tem variância alta nesse tamanho); a decisão é reduzida a binária (Incluir/Excluir) para o κ , ignorando a gradação "com ressalvas"; os escores do ChatGPT foram **extraídos automaticamente** de seus pareceres (`gen_comparison.py`), sujeitos a variação de formato. Ainda assim, a convergência (90% / κ 0,74 / banda 100% / RQ4–RQ5 100%) é consistente e interpretável.

12.7 Extração de dados e reprodutibilidade

Texto dos PDFs extraído via **PDFKit** (não houve renderização de página). Escores consolidados em `resultados-consolidados.csv` ; comparação gerada por `scripts/gen_comparison.py` ; gráficos por `scripts/gen_charts.py` ; este relatório em PDF por `scripts/build_pdf.py` .

Referências. Kitchenham, B. et al. (2009). *Systematic literature reviews in software engineering – A systematic literature review*. Information and Software Technology. · Cohen, J. (1960). *A coefficient of agreement for nominal scales*. Educational and Psychological Measurement. · Landis, J.R. & Koch, G.G. (1977). *The measurement of observer agreement for categorical data*. Biometrics.

_Gerado a partir de `reviews/resultados-consolidados.csv` (20 estudos). Estatísticas: SCORE_RQ médio 3,83; SCORE_QA médio 3,50; 14 Banda Alta; RQ4 plenamente respondida em apenas 4/18. Concordância entre avaliadores: decisão 90%, Cohen's $\kappa = 0,74$ (substancial)._