

Agentic AI Copilot para Resposta a Incidentes: Uma Revisão da Literatura

Valdomiro de Oliveira Souza Júnior

¹Programa de Pós-Graduação em Computação Aplicada – Universidade do Vale do Rio dos Sinos (Unisinos)
São Leopoldo – RS – Brazil

valdomiros@edu.unisinos.br

Abstract. *This paper presents a systematic literature review on the application of Agentic Artificial Intelligence (Agentic AI) in the context of incident response. Based on the methodological guidelines for Systematic Literature Reviews in Software Engineering by Kitchenham et al. (2009), this research aims to synthesize existing evidence on how autonomous systems, capable of perception, reasoning, action, and learning, can act as cognitive copilots, supporting technology teams (SRE, Engineering, Support, among others) in complex and high-criticality operational environments. The review analyzes studies published between 2020 and 2025, addressing advances in AIOps, Large Language Models (LLMs), Multi-Agent Systems, and adaptive autonomy frameworks applied to the incident lifecycle. The results indicate a significant evolution from traditional automation to agentic copilot architectures, capable of reducing mean time to detection and resolution (MTTD/MTTR), improving observability, and decreasing the cognitive load on technical teams.*

Resumo. *Este artigo apresenta uma fundamentada nas diretrizes metodológicas de Systematic Literature Reviews in Software Engineering de Kitchenham et al. (2009), esta pesquisa tem como objetivo sintetizar as evidências existentes sobre como sistemas autônomos, capazes de perceber, raciocinar, agir e aprender, podem atuar como copilotos cognitivos, apoiando equipes de tecnologia (SRE, Engenharia, Suporte, entre outros times) em ambientes complexos e de alta criticidade operacional. A revisão analisa estudos publicados entre 2020 e 2025, abordando avanços em AIOps, Large Language Models (LLMs), Multi-Agent Systems e frameworks aplicados ao ciclo de vida de incidentes. Os resultados indicam uma evolução significativa da automação tradicional para arquiteturas de copilotos agênticos, capazes de reduzir o tempo médio de detecção e resolução (MTTD/MTTR), aprimorar a observabilidade e diminuir a sobrecarga cognitiva dos times de tecnologia.*

1. Introdução

O aumento da complexidade de sistemas distribuídos e arquiteturas baseadas em microsserviços vem ampliando os desafios de confiabilidade, disponibilidade e segurança em serviços digitais. Nesse cenário, a consolidação de práticas de Site Reliability Engineering (SRE) buscou equilibrar inovação e estabilidade (BEYER, 2016), mas o custo operacional cresceu junto com a sofisticação das plataformas.

Ao mesmo tempo, a explosão de dados de observabilidade, como métricas, logs e traces, elevou a carga cognitiva das equipes e limitou a capacidade humana de detecção, diagnóstico e resposta em tempo hábil. Soluções de AIOps avançaram na correlação e automação de alertas, porém têm limitações quando a demanda exige sistemas que não apenas recomendem ações, mas que consigam planejar, agir e aprender continuamente em ambientes dinâmicos (ACHARYA, 2025).

Apesar do avanço recente de Agentic AI, ainda há uma lacuna na literatura quanto a como esses sistemas podem ser aplicados, com segurança e governança, ao ciclo de vida de incidentes. Em especial, faltam sínteses sobre níveis de autonomia, arquiteturas, mecanismos de controle (*guardrails*) e o papel da supervisão humana nos modos Human-in-the-Loop e Human-on-the-Loop.

Diante disso, este estudo busca responder à seguinte pergunta: como e em que medida a Agentic AI pode atuar como copilot ou agente autônomo na resposta a incidentes, apoiando equipes de tecnologia em ambientes de alta complexidade operacional? Para responder, conduzimos uma Revisão Sistemática da Literatura, mapeando frameworks e arquiteturas, analisando benefícios e riscos reportados, e identificando lacunas e tendências futuras para adoção responsável de *Agentic AI* em incident response.

2. Objetivos da Revisão

2.1. Objetivo geral

Investigar a literatura científica sobre o uso de *Agentic AI* em cenários de Resposta a Incidentes, identificando *frameworks*, arquiteturas, benefícios e desafios na sua integração com as melhores práticas de Engenharia de Software e Operações de TI.

2.2. Objetivos específicos

- Mapear o estado da arte de soluções de IA agêntica aplicadas a *incident response* e *incident management*.
- Identificar métodos, arquiteturas e modelos cognitivos empregados em copilotos autônomos.
- Avaliar impactos na redução de MTTR/MTTD e na eficiência operacional.
- Identificar lacunas de pesquisa e tendências futuras em *Agentic AI*.

3. Metodologia

Esta pesquisa foi conduzida como uma Revisão Sistemática da Literatura (RSL), em conformidade com as diretrizes para engenharia de software propostas por Kitchenham et al. (2009). O objetivo central desta RSL é identificar, avaliar criticamente e sintetizar as evidências existentes sobre a aplicação de *Agentic Artificial Intelligence (Agentic AI)* — atuando como copiloto ou agente autônomo — no contexto de resposta a incidentes em sistemas complexos de software.

A metodologia foi estruturada em cinco etapas principais: definição do protocolo da revisão, estratégia de busca, seleção dos estudos, avaliação da qualidade de cada artigo e, por fim, a extração e síntese dos dados.

3.1. Estratégia de busca

A estratégia de busca foi realizada por meio de consultas em múltiplas bases de dados científicas, abrangendo IEEE Xplore, ACM Digital Library e Google Scholar, e os estudos selecionados foram publicados nos periódicos e conferências listados na tabela 2. Neste estudo optamos pelo uso de uma *string* de busca única e abrangente, aplicada de forma consistente em todas as bases, a fim de garantir uniformidade e reduzir vieses decorrentes de variações sintáticas específicas de cada repositório.

Tabela 1. *string* de busca (Query)

("Agentic AI"	OR	"Multi-Agent System*")	AND
("Incident Response"	OR	"Incident Management"	OR
"Incident Resolution"	OR	"HITL"	OR "HOTL")

3.2. Periódicos e conferências selecionadas

Tabela 2. Periódicos e Conferências Selecionados

Fontes

ACM Computing Surveys
ACM Transactions on Software Engineering and Methodology
Algorithms
Array
F1000Research
Future Internet
IEEE Access
Information Fusion
Journal of Systems and Software
Telecommunications Policy

3.3. Critérios de inclusão e exclusão

Dos 110 estudos inicialmente identificados, 19 atenderam aos critérios de inclusão. As publicações concentram-se principalmente entre 2020 e 2025, com uma concentração de 78,95% dos artigos nos anos de 2024 e 2025, refletindo o surgimento recente do conceito de *Agentic AI* e sua convergência com *AIOps* e resposta a incidentes.




Figura 1. Fluxo PRISMA de identificação, triagem, elegibilidade e inclusão dos estudos

Tabela 3. Métricas Bibliométricas e Qualis dos Estudos Selecionados

Paper ID	Journal	Ano	Cit.	Refs.	SJR	Qualis
P1	F1000Research	2025	1	217	Q1	A2
P2	Array	2025	56	42	Q1	A1
P3	Algorithms	2025	1	53	Q2	A2
P4	ACM Trans. on Softw. Eng. and Methodology	2024	80	146	Q1	A2
P5	ACM Computing Surveys	2025	7	163	Q1	A1
P6	IEEE Access	2025	1	129	Q1	A1
P7	IEEE Access	2020	7	45	Q1	A1
P8	IEEE Access	2024	55	179	Q1	A1
P9	Information Fusion	2025	105	267	Q1	A1
P10	IEEE Access	2025	96	101	Q1	A1
P11	IEEE Access	2024	1	42	Q1	A1
P12	IEEE Access	2024	60	136	Q1	A1
P13	IEEE Access	2025	6	56	Q1	A1
P14	Telecommunications Policy	2025	18	12	Q1	A1
P15	Future Internet	2025	8	111	Q2	A2
P16	ACM Computing Surveys	2023	50	123	Q1	A1
P17	IEEE Access	2023	182	65	Q1	A1
P18	Journal of Systems and Software	2024	7	28	Q1	A1
P19	IEEE Access	2021	27	58	Q1	A1

Legenda: Cit. = Citações; Refs. = Referências usadas no artigo; SJR = SCImago Journal Rank.

3.4. Perguntas de pesquisa

Tabela 4. Perguntas de pesquisa

Código	Questão de Pesquisa
RQ1	Quais capacidades e níveis de autonomia (planejamento, memória, uso de ferramentas e supervisão humana) caracterizam Agentic AI e como essas capacidades afetam tomada de decisão em ambientes complexos?
RQ2	Quais arquiteturas e mecanismos de implementação (orquestração, memória, ferramentas, políticas/guardrails e observabilidade) sustentam Agentic AI em produção?
RQ3	Quais evidências (quantitativas e qualitativas) reportam benefícios de Agentic AI, e quais métricas são usadas (ex.: tempo de resposta, qualidade de decisão, carga operacional), especialmente em cenários operacionais como IR?
RQ4	Quais riscos e desafios (segurança, robustez, governança e accountability) limitam o uso responsável de Agentic AI em sistemas críticos?
RQ5	Quais lacunas e direções futuras são apontadas (avaliação/benchmarking, threat models, governança, observabilidade e alinhamento) para ampliar adoção responsável de Agentic AI?

4. Resultados

Tabela 5: Revisão sistemática dos estudos

ID	Artigo	RQ1	RQ2	RQ3	RQ4	RQ5	SCORE
P1	Trustworthy agentic AI systems: a cross-layer review of architectures, threat models, and governance strategies for real-world deployment	T	T	P	T	T	4,5
P2	The role of agentic AI in shaping a smart future: A systematic review	T	P	P	T	T	4
P3	A Research Landscape of Agentic AI and Large Language Models: Applications, Challenges and Future Directions	T	T	T	T	T	5
P4	LLM-Based Multi-Agent Systems for Software Engineering: Literature Review, Vision and the Road Ahead	T	T	P	T	T	4,5
P5	A Survey of AIOps in the Era of Large Language Models	P	P	T	P	T	3,5
P6	Agentic AI: A Comprehensive Survey of Technologies, Applications, and Societal Implications	T	T	P	T	T	4,5
P7	Artificial Empathy: A New Perspective for Analyzing and Designing Multi-Agent Systems	P	P	P	P	P	2,5
P8	Applications, Challenges, and Future Directions of Human-in-the-Loop Learning	P	P	P	T	P	3
P9	AI Agents vs. Agentic AI: A Conceptual taxonomy, applications and challenges	T	T	P	T	T	4,5
P10	Agentic AI: Autonomous Intelligence for Complex Goals — A Comprehensive Survey	T	T	P	T	T	4,5
P11	Co-evolving Multi-Agent Transfer Reinforcement Learning via Scenario Independent Representation	P	P	P	P	P	2,5

T: Total (1.0) P: Parcial (0.5)

Continua na próxima página

Tabela 4 (Continuação): Revisão sistemática dos estudos

ID	Artigo	RQ1	RQ2	RQ3	RQ4	RQ5	SCORE
P12	Enhancing Autonomous System Security and Resilience with Generative AI: A Comprehensive Survey	T	T	P	T	T	4,5
P13	Retail Resilience Engine: An Agentic AI Framework for Building Reliable Retail Systems With Test-Driven Development Approach	P	T	T	P	T	4
P14	Transforming Cybersecurity with Agentic AI to Combat Emerging Cyber Threats	P	P	T	P	P	3
P15	The Rise of Agentic AI: A Review of Definitions, Frameworks, Architectures, Applications, Evaluation Metrics, and Challenges	T	T	P	T	T	4,5
P16	A Joint Study of the Challenges, Opportunities, and Roadmap of MLOps and AIOps: A Systematic Survey	P	P	P	T	P	3
P17	A Review of Trustworthy and Explainable Artificial Intelligence (XAI)	T	T	T	T	T	5
P18	An architecture for model-based and intelligent automation in DevOps	P	P	P	P	P	2,5
P19	Agent System Mining: Vision, Benefits, and Challenges	T	T	P	P	T	4

T: Total (1.0) P: Parcial (0.5)

A classificação de cada *Research Question*, categorizada como 'Parcialmente Respondida' (P) ou 'Totalmente Respondida' (T), segue os critérios de extração estipulados no protocolo desta RSL, com base nas diretrizes de Kitchenham et al. (2009).

4.1. Avaliação de Qualidade

Para assegurar a confiabilidade das fontes selecionadas, foi aplicado o procedimento de Avaliação de Qualidade (*Quality Assessment* - QA). Este processo visa ponderar a relevância metodológica de cada estudo, mitigando riscos de viés e garantindo que as conclusões desta revisão sistemática da literatura (RSL ou **SLR**) sejam fundamentadas em evidências sólidas, conforme as diretrizes de Kitchenham et al. (2009).

Cada artigo selecionado foi submetido a uma leitura técnica completa e pontuado de acordo com quatro critérios de qualidade (QA1 a QA4), utilizando uma escala ternária para minimizar a subjetividade da avaliação:

- **Sim (Y) – 1.0 ponto:** O critério foi plenamente atendido, com descrição explícita e detalhada no texto.
- **Parcial (P) – 0.5 ponto:** O critério foi atendido, mas apresenta descrições genéricas, incompletas ou baseadas apenas em exemplos ilustrativos (*toy examples*) sem dados reais.
- **Não (N) – 0.0 ponto:** A informação está ausente ou o critério não foi atendido.

A Tabela 6 detalha as definições operacionais e as perguntas de verificação (*checklists*) utilizadas para julgar cada critério.

Tabela 6. Critérios de Avaliação de Qualidade (QA) e Definições de Pontuação			
ID	Critério	Pergunta de Verificação (Checklist)	Rubrica de Pontuação
QA1	Objetivos Claros	O estudo define explicitamente o problema de negócio ou técnico (ex: fadiga de alertas, complexidade de logs) e como a abordagem de IA Agêntica propõe resolvê-lo?	(Y) Problema e solução agêntica explícitos. (P) Problema vago ou conexão fraca com a solução. (N) Sem definição clara do problema.
QA2	Metodologia Replicável	A arquitetura do sistema (framework, design dos agentes, fluxos) e o cenário experimental são descritos com detalhes suficientes para replicação em outros estudos?	(Y) Arquitetura, tecnologias e parâmetros detalhados. (P) Descrição textual genérica sem detalhes de implementação. (N) Metodologia omitida.
QA3	Base de Evidências Sólidas	Há validação empírica da proposta através de experimentos controlados, estudos de caso industriais ou simulações com métricas quantitativas?	(Y) Resultados quantitativos rigorosos ou estudo de caso real. (P) Apenas prova de conceito simples, exemplo motivador ou simulação sem métricas. (N) Artigo puramente teórico/visão.
QA4	Conclusões Coerentes	As conclusões derivam logicamente das evidências apresentadas e as limitações do estudo são discutidas explicitamente?	(Y) Conclusões baseadas nos dados; limitações citadas. (P) Conclusões genéricas; limitações não discutidas. (N) Conclusões desconectadas dos resultados (overclaiming).

A pontuação máxima possível para um estudo é 4.0. Com base na nota final acumulada das quatro QAs, os estudos foram categorizados para fins de análise e síntese de dados:

- **Alta Qualidade (≥ 3.0):** Estudos com alto rigor empírico e metodológico. As evidências extraídas destes estudos têm peso maior na resposta às questões de pesquisa sobre eficácia e desempenho.
- **Média Qualidade (1.5 a 2.5):** Estudos que apresentam propostas técnicas válidas (frameworks, arquiteturas), mas cuja validação é limitada (ex: artigos de visão ou propostas iniciais). Estes estudos contribuem principalmente para a taxonomia e identificação de tendências arquiteturais.
- **Baixa Qualidade (< 1.5):** Estudos que falham na descrição metodológica ou na apresentação de resultados. Foram utilizados apenas para contextualização teórica, sendo excluídos da síntese de evidências quantitativas.

Tabela 7. Avaliação de qualidade dos estudos

ID	TIPO DE ESTUDO	QA1	QA2	QA3	QA4	SCORE
P1	Survey	Y (1.0)	Y (1.0)	N (0.0)	P (0.5)	2.5
P2	Narrative/Systematic review	Y (1.0)	N (0.0)	P (0.5)	P (0.5)	2.0
P3	Literature review	Y (1.0)	Y (1.0)	P (0.5)	Y (1.0)	3.5
P4	Literature review	Y (1.0)	Y (1.0)	Y (1.0)	Y (1.0)	4.0
P5	Survey	Y (1.0)	P (0.5)	N (0.0)	Y (1.0)	2.5
P6	Survey	Y (1.0)	P (0.5)	Y (1.0)	Y (1.0)	3.5
P7	Conceptual	Y (1.0)	Y (1.0)	Y (1.0)	Y (1.0)	4.0
P8	Survey	Y (1.0)	N (0.0)	P (0.5)	Y (1.0)	2.5
P9	Conceptual survey / taxonomy paper	Y (1.0)	Y (1.0)	Y (1.0)	Y (1.0)	4.0
P10	Comprehensive survey	Y (1.0)	N (0.0)	Y (1.0)	Y (1.0)	3.0
P11	Empirical Study	Y (1.0)	Y (1.0)	Y (1.0)	Y (1.0)	4.0
P12	Comprehensive survey	Y (1.0)	N (0.0)	P (0.5)	Y (1.0)	2.5
P13	Empirical Study	Y (1.0)	Y (1.0)	P (0.5)	Y (1.0)	3.5
P14	Conceptual	Y (1.0)	N (0.0)	P (0.5)	P (0.5)	2.0
P15	Review	Y (1.0)	P (0.5)	Y (1.0)	Y (1.0)	3.5
P16	Systematic Survey	Y (1.0)	Y (1.0)	P (0.5)	Y (1.0)	3.5
P17	Review	Y (1.0)	N (0.0)	Y (1.0)	Y (1.0)	3.0
P18	Case-study	Y (1.0)	Y (1.0)	P (0.5)	Y (1.0)	3.5
P19	Vision Paper	Y (1.0)	P (0.5)	P (0.5)	Y (1.0)	3.0

4.2. Principais resultados dos estudos




Figura 2. Mapa de Citações Cruzadas (Tamanho do nó = Relevância por Citação)

A literatura analisada converge para um diagnóstico claro, a fronteira de pesquisa em *Agentic AI for Incident Response* não está mais na capacidade de “entender” incidentes, mas na capacidade de agir com segurança. Em termos operacionais, surveys em LLM4AIOps consolidam o ciclo como Failure Perception → Root Cause Analysis → Assisted Remediation e mostram que a remediação ainda é majoritariamente tratada como recomendação, não como execução automática, justamente por risco e falta de confiança em produção (ZHANG, 2025; DIAZ-DE-ARCAYA, 2023). Essa leitura reposiciona o “gap” central da área: não é mais “fazer o LLM raciocinar”, e sim construir arquiteturas e controles que tornem a execução verificável, auditável e reversível (BANDI, 2025; ADABARA, 2025).

Um segundo resultado recorrente é arquitetural: a literatura tende a rejeitar agentes monolíticos e, em seu lugar, prioriza sistemas hierárquicos e multiagentes com papéis especializados e validação cruzada. Revisões sobre sistemas multiagentes baseados em LLM destacam padrões como orquestrador, programador, revisor e tester, operando em ciclos iterativos de feedback e checagem (HE, 2025; PATI, 2025). No domínio de IR, Sapkota et al. (2026) explicitam esse princípio ao descrever um fluxo com quatro agentes especializados (classificador de ameaça, investigador de logs, analista de compliance e planejador de mitigação), reforçando que “agentic” é, sobretudo, orquestração de multiagente e não apenas um agente com ferramentas. Na prática, o efeito desse desenho proposto por Sapkota et al. (2026) é reduzir a propagação de erro e aumentar a capacidade de testar e confirmar (BANDI, 2025; HE, 2025).

Quando a discussão migra de arquitetura para confiabilidade, o conjunto de artigos oferece um achado importante: guardrails efetivos precisam ser técnicos e executáveis, não apenas políticas em prompt. O framework RRE (MISHRA, 2025) introduz um loop de confiabilidade inspirado em TDD, no qual o agente gera e executa testes como mecanismo de validação antes de mudanças para melhorar o controle (MISHRA, 2025). Essa abordagem está alinhada com a recomendação mais ampla de que a avaliação de sistemas agênticos deve incluir métricas de execução e, quando necessário a validação humana, dado o risco de alucinação (BANDI, 2025; KUMAR, 2024). Além disso, é importante valorizar as evidências quantitativas quando existirem, como o “Similarity Index” reportado como aproximação de decisões humanas em contexto aplicado, sem confundir isso com prova direta de redução de MTTR/MTTD em SRE (MISHRA, 2025).

Um quarto resultado é que segurança e governança aparecem como requisitos de primeira classe, e não como apêndice. A síntese de P1 destaca lacunas críticas em benchmarking, integridade de memória, defesas adversariais e incorporação normativa, defendendo modelos em camadas e supervisão resiliente para implantação no mundo real (ADABARA, 2025; ANDREONI, 2024). Esse enquadramento muda o critério de “funciona” para “funciona sob ataque, sob pressão e com auditoria”, o que aproxima a agenda de Agentic AI das exigências típicas de SRE: runtime monitoring, trilhas de auditoria e mecanismos de override e contenção (ADABARA, 2025; CHAMOLA, 2023).

Por fim, os resultados apontam duas fricções que costumam ser subestimadas quando se fala em autonomia para IR em ambientes reais: dinamismo e telemetria complexa. Primeiro, há um alerta explícito de que traces seguem pouco explorados com LLMs apesar do potencial, e que tempo real, custo e latência são limitadores concretos para remediação automatizada em produção (ZHANG et al., 2025). Segundo, para ambientes que mudam continuamente, a literatura de aprendizado multiagente traz uma analogia metodológica útil: curriculum transfer learning e mecanismos para reduzir catastrophic forgetting sugerem como um agente pode aprender com incidentes novos sem degradar desempenho em padrões antigos, o que em SRE se traduz em resiliência contra drift operacional (SIDDIQUA, 2024; PATI, 2025).

5. Lacunas e direções futuras de pesquisa

Com base na análise da literatura, as lacunas e direções futuras de pesquisa para o campo de IA Agêntica aplicada à Resposta a Incidentes (IR) podem ser sintetizadas nos seguintes eixos fundamentais:

5.1. Transição da Recomendação para a Execução Autônoma e Segura

A literatura revela que o estágio de remediação em LLM4AIOps ainda é tratado majoritariamente como recomendação de soluções ou triagem de incidentes, e não como execução automática. O "gap" central reside na falta de confiança em permitir que agentes ajam diretamente em sistemas de produção devido ao risco de cascatas de erro e à ausência de mecanismos de reversão. Pesquisas futuras devem focar em arquiteturas que tornem a execução verificável, auditável e reversível (rollback) (ZHANG, 2025; BANDI, 2025).

5.2. Exploração de Telemetria Complexa (*Traces*)

Embora logs e métricas sejam fontes de dados bem exploradas, há uma lacuna crítica na integração de dados de *traces* em sistemas baseados em LLM. *Traces* são fundamentais para entender interações entre

microsserviços, mas sua alta complexidade e volume dificultam o processamento por modelos de linguagem. Direções futuras apontam para o desenvolvimento de métodos de representação eficientes, como o uso de *prompt embedding*, para que LLMs compreendam sequências aninhadas de eventos (ZHANG, 2025).

5.3. Integridade de Memória e Resolução de Conhecimento Contraditório

Sistemas agênticos dependem de memória persistente, o que os torna vulneráveis a envenenamento de memória (*memory poisoning*) e à persistência de dados sensíveis ou maliciosos. Além disso, agentes frequentemente enfrentam conhecimentos contraditórios provenientes de fontes dinâmicas, o que pode levar a decisões inconsistentes. É necessário avançar em arquiteturas de memória que utilizem grafos de conhecimento temporais e mecanismos robustos de resolução de conflitos semânticos (ADABARA, 2025).

5.4. Governança, *Accountability* e Riscos Adversariais

A autonomia agêntica introduz riscos como a emergência de *shadow agents* e a propagação lateral de ataques em ecossistemas multiagentes. Existe um lacuna de responsabilização (*accountability gap*) quando múltiplos agentes colaboram para uma decisão errônea. Pesquisas futuras devem focar em:

- **Auditabilidade de ponta a ponta:** Criação de trilhas de auditoria imutáveis baseadas em *block-chain* para registrar o rastro de decisão.
- **Mecanismos de Revogação:** Desenvolvimento de protocolos de “kill-switch” e revogação de credenciais em tempo real para agentes comprometidos (ADABARA, 2025; KSHETRI, 2025).

5.5. Raciocínio Causal vs. Correlação Estatística

A maioria dos agentes atuais opera com base em correlações estatísticas herdadas dos LLMs, falhando em compreender relações de causa e efeito. Isso torna os sistemas frágeis diante de cenários inéditos ou mudanças drásticas no ambiente operacional. Uma direção essencial é a incorporação de inferência causal e modelagem de intervenção diretamente nos fluxos de trabalho, permitindo que o sistema antecipe o impacto real de suas ações de mitigação (SAPKOTA, 2026; ADABARA, 2025).

5.6. Eficiência de Recursos e Sustentabilidade

O custo de inferência e a latência em tempo real são limitadores concretos para a percepção de falhas em produção. Pesquisas futuras devem explorar o uso de Modelos de Linguagem Pequenos (SLMs) e técnicas para permitir que a inteligência agêntica rode de forma distribuída e eficiente em dispositivos de borda (*edge computing*) (BROHI, 2025; BANDI, 2025).

Referências

ADABARA, I. et al. Trustworthy agentic AI systems: a cross-layer review of architectures, threat models, and governance strategies for real-world deployment. *F1000Research*, v. 14, p. 905, 11 set. 2025b.

HOSSEINI, S.; SEILANI, H. The role of agentic AI in shaping a smart future: A systematic review. *Array*, Elsevier B.V., 1 jul. 2025.

BROHI, S. et al. A Research Landscape of Agentic AI and Large Language Models: Applications, Challenges and Future Directions. *Algorithms*, Multidisciplinary Digital Publishing Institute (MDPI), 1 ago. 2025.

HE, J.; TREUDE, C.; LO, D. LLM-Based Multi-Agent Systems for Software Engineering: Literature Review, Vision and the Road Ahead. 18 jul. 2025.

ZHANG, L. et al. Article 111.. 2025. A Survey of AIOps in the Era of Large Language Models. *Journal of the ACM*. [s.l: s.n.]. Disponível em: <https://doi.org/10.1145/3746635>.

PATI, A. K. Agentic AI: A Comprehensive Survey of Technologies, Applications, and Societal Implications. *IEEE Access*, v. 13, p. 151824–151837, 2025.

CHEN, J. et al. Artificial empathy: A new perspective for analyzing and designing multi-agent systems. *IEEE Access*, v. 8, p. 183649–183664, 2020.

KUMAR, S. et al. Applications, Challenges, and Future Directions of Human-in-the-Loop Learning. *IEEE Access*, v. 12, p. 75735–75760, 2024.

SAPKOTA, R.; ROUMELIOTIS, K. I.; KARKEE, M. AI Agents vs. Agentic AI: A Conceptual taxonomy, applications and challenges. *Information Fusion*, v. 126, 1 fev. 2026.

ACHARYA, D. B. et al. Agentic AI: Autonomous Intelligence for Complex Goals - A Comprehensive Survey. *IEEE Access*, v. 13, p. 18912–18936, 2025.

SIDDIQUA, A. et al. Co-Evolving Multi-Agent Transfer Reinforcement Learning via Scenario Independent Representation. *IEEE Access*, v. 12, p. 99439–99451, 2024.

ANDREONI, M. et al. Enhancing Autonomous System Security and Resilience With Generative AI: A Comprehensive Survey. *IEEE Access*, v. 12, p. 109470–109493, 2024, doi: 10.1109/ACCESS.2024.3439363.

MISHRA, L. N.; SENAPATI, B. Retail Resilience Engine: An Agentic AI Framework for Building Reliable Retail Systems With Test-Driven Development Approach. *IEEE Access*, v. 13, p. 50226–50243, 2025.

KSHETRI, N. Transforming Cybersecurity with Agentic AI to Combat Emerging Cyber Threats. [s.l: s.n.]. Disponível em: <https://ssrn.com/abstract=5159598>.

BANDI, A. et al. The Rise of Agentic AI: A Review of Definitions, Frameworks, Architectures, Applications, Evaluation Metrics, and Challenges. *Future Internet*, Multidisciplinary Digital Publishing Institute (MDPI), 1 set. 2025.

DIAZ-DE-ARCAYA, J. et al. A Joint Study of the Challenges, Opportunities, and Roadmap of MLOps and AIOps: A Systematic Survey. *ACM Computing Surveys*, v. 56, n. 4, 30 abr. 2024.

CHAMOLA, V. et al. A Review of Trustworthy and Explainable Artificial Intelligence (XAI). *IEEE Access*, v. 11, p. 78994–79015, 2023.

ERAMO, R. et al. An architecture for model-based and intelligent automation in DevOps. *Journal of Systems and Software*, v. 217, 1 nov. 2024.

TOUR, A.; POLYVYANY, A.; KALENKOVA, A. Agent system mining: Vision, benefits, and challenges. *IEEE Access*, v. 9, p. 99480–99494, 2021.

B. Beyer, C. Jones, J. Petoff, and N. R. Murphy, *Site Reliability Engineering: How Google Runs Production Systems*. Sebastopol, CA: O'Reilly Media, 2016. [Online]. Disponível em: <https://sre.google/sre-book/table-of-contents/>. Acessado: Sep. 22, 2025.

Anexos




Figura 3. Interesse ao longo do tempo dos termos de busca.

Fonte: <https://trends.google.com.br/trends/explore?date=2022-11-27%202025-11-27&q=Agentic%20AI,Multi-Agent,IA%20Ag%C3%AAntica&hl=pt>